

MSc BIHAR

Mise en Situation Professionnelle (MESPR)

CastagNet

un modèle d'IA qui va faire du bruit

Programme	MSc BIHAR — ESTIA
Type d'épreuve	Mise en Situation Professionnelle Reconstituée (MESPR)
Dates	Lundi 31 août – mercredi 2 septembre 2026 (3 jours)
Enseignants référents	Nicolas Huloux & Nicolas Gensollen
Modalité	Individuel

1. Objectifs du projet

Ce projet mobilise les compétences suivantes du référentiel BIHAR (bloc BC4B, module M24-IA) :

Compétence	Intitulé
C28	Analyser une problématique liée au traitement de big data (volumes, vitesse, variété) pour élaborer une stratégie d'analyse
C29	Concevoir et évaluer des modèles statistiques / d'apprentissage automatique (ML, deep learning) répondant à une problématique métier
C30	Optimiser l'exploitation des données (ETL, outils IA) en respectant le RGPD
C31	Concevoir une base/organisation de données répondant aux besoins des traitements analytiques et IA
C32	Schématiser et concevoir un programme d'IA répondant aux besoins fonctionnels du projet

Temps alloué au travail sur le projet

- Lundi 31 août 2026 (1 jour)
- Mardi 1er septembre 2026 (1 jour)

- Mercredi 2 septembre 2026 (1 jour)

2. Contexte du projet


Vous intégrez, pour 3 jours, l'équipe data du projet CastagnIA : une machine de tri automatique de châtaignes sèches analyse en temps réel le flux de fruits, via 12 caméras (positions « dessus »/T et « dessous »/B, 6 emplacements), pour les classer en 4 catégories : Conforme, NON Conforme, PIETRA, Vide.

L'équipe vous confie le dépôt du projet en l'état, avec pour objectif de le faire progresser sur trois fronts :

- la qualité et la complétude de la donnée labellisée,
- la robustesse du modèle de classification,
- la compatibilité de la solution avec les contraintes de production.

Le partenaire du projet, le GRPTMC (Groupement Régional des Producteurs et Transformateurs de Châtaignes et Marrons Corses), a formalisé ses exigences qualité dans un cahier des charges (voir Annexe A). Ce document contient les critères précis que votre modèle final devra respecter — il vous revient de les identifier et de les justifier dans vos rapports, ils ne sont pas redonnés ici.

Les 4 catégories du tri — exemples issus du dataset



Images brutes issues de la caméra du dessus (T), sans retraitement — la faible résolution et le contraste font partie des conditions réelles d'acquisition.

3. Environnement et données fournies

Un dépôt Git `castagnia_data` (copie identique pour chaque candidat, sous forme d'archive .zip) est mis à votre disposition, avec :

- `images/` — 35 254 images (suivies par DVC, ~975 Mo, accès en lecture au drive partagé), format de nom `annee_label_Cam_{T|B}_{numCamera}_{numEchantillon}.jpg` ;
- `labels_principal.csv` — labels d'entraînement et tags associés à chaque image ;
- `labels_masked.csv` — annotations vide/châtaigne de référence, à ne pas modifier ;
- `labeling_tool/` — application Streamlit de relecture/labelisation ;
- `training/` — pipeline d'entraînement (`make_splits.py`, `train.py`, `evaluate.py`, `export_onnx.py`), avec 4 configurations d'architecture prêtes à l'emploi ;

- Rapport_Dataset_Chataignes.pdf — rapport statistique existant sur le dataset.

Schéma de labels_principal.csv

Colonne	Description
filename	nom du fichier image
year, cam_position, cam_num, sample_num	déduits du nom de fichier
label_filename	label déduit du nom de fichier (référence, jamais modifié)
label_principal	cible d'entraînement : Conforme / NON Conforme / PIETRA / Vide
multiple	plusieurs châtaignes visibles sur l'image
chunk	présence d'un morceau / débris (pas une châtaigne entière)
mixed_quality	mélange de qualités sur la même image
reviewed	ligne relue/validée par l'équipe
labeled_by	pseudo ou identifiant de la personne (ou du processus) ayant validé la ligne

En complément, un extrait vidéo de 30 secondes de la machine de tri vous est fourni séparément (matériel d'examen).

Aucune image supplémentaire ne doit être ajoutée au drive DVC partagé : tout travail de constitution de nouvelles données reste local à votre environnement de travail.

4. Travail demandé

Le projet est découpé en trois volets. Vous êtes libre d'organiser votre temps sur les 3 jours, mais l'ensemble des livrables listés doit être rendu au moment de la soutenance.

4.1 Qualité et complétude de la donnée

(Compétences C28, C31)

- À partir de l'extrait vidéo fourni, réalisez un découpage manuel en images puis un recadrage (crop) autour de chaque châtaigne détectée.
- Constituez, pour ce sous-ensemble et pour toutes les autres images déjà labellisées, un moyen de relier entre elles les deux vues (caméra T et caméra B) d'une même châtaigne : c'est un point sur lequel vous devrez faire des choix et les justifier.
- Organisez ces éléments (images extraites, correspondances T/B, labels) dans un dépôt Git que vous construirez vous-même.

- Terminez la labelisation d'un sous-ensemble du reliquat non relu de labels_principal.csv (année 2026) via labeling_tool/ (environ 500 images restantes).
- Produisez un rapport de qualité du dataset actualisé (répartition par label / année / caméra, taux de relecture, part de cas ambigus).
- Constituez le dataset final destiné à l'entraînement (§4.2) en tenant compte de l'hétérogénéité du processus de diagnostic ayant produit les labels existants : les décisions prises (inclusion, exclusion, arbitrage) doivent être explicites et argumentées.
- Proposez une évolution du schéma ou du processus de labelisation collaborative (par exemple sur la gestion des conflits Git lors de la mise à jour du CSV par plusieurs personnes).

Travail à rendre

- Rapport écrit : description de l'extraction des images de la vidéo, analyse de la qualité du dataset avant/après vos interventions, décisions prises sur les cas ambigus et sur l'hétérogénéité du diagnostic, proposition d'une méthode pour relier les images T et B à la même châtaigne.
- Données et code : dépôt Git constitué (extraction vidéo, correspondance T/B) et labels_principal.csv mis à jour.

4.2 Modélisation et comparaison d'architectures

(Compétences C29, C32)

- Générez les jeux d'entraînement/validation/test à partir de la donnée constituée en §4.1, en justifiant votre méthode de découpage.
- Entraînez et évaluez plusieurs modèles, dont au moins un CNN entraîné « à la main » (architecture définie et codée par vous) servant de baseline, en complément des architectures pré-entraînées disponibles dans training/.
- Sélectionnez le meilleur modèle au regard des critères du cahier des charges (Annexe A).
- Analysez les matrices de confusion et l'historique d'entraînement.
- Suivez et visualisez vos expérimentations dans MLflow.

Travail à rendre

- Rapport écrit : comparatif des modèles entraînés, justification du modèle retenu au regard du cahier des charges, analyse des erreurs.
- Code : scripts et configurations utilisés, traces MLflow.

POUR ALLER PLUS LOIN :

L'information dans l'image principale est centrée sur le cercle réduit. Travailler sur des architectures parcimonieuses de CNN radiale peut être une piste intéressante pour réduire le temps d'inférence (moins d'opérations) et augmenter la précision (cohérence radiale).

4.3 Export et compatibilité production

(Compétence C30)

- Exportez le modèle retenu au format ONNX et vérifiez le.
- Estimez ou mesurez la latence d'inférence de votre modèle, et discutez sa compatibilité avec l'exigence de production du cahier des charges (Annexe A) sur l'analyse simultanée des 12 flux caméra.

Travail à rendre

- Rapport écrit : résultats de l'export, analyse de latence, recommandation finale (architecture retenue et justification vis-à-vis de la production).
- Modèle : model.onnx.

5. Grille d'évaluation

Compétence	Critère d'évaluation	Points
C28	Analyse de la problématique data précise et rigoureuse	5
C29	Choix et évaluation des modèles justifiés (métriques adaptées)	5
C30	Exploitation/optimisation des données	2
C31	Organisation des données cohérente avec les traitements IA	5
C32	Conception du programme d'IA répondant au besoin fonctionnel	3
Total		20

Annexes

- Annexe A — Cahier des charges GRPTMC (extrait qualité) — document séparé.